

Inhaltsverzeichnis

1	TensorFlow	1
2	Anforderungsanalyse	2
	Anforderungen	2
	Einflussfaktoren	3
3	Architekturentwurf	4
	Szenarien	4
	Kontext-Sicht	4
	Verhaltenssicht (Architekturbausteine)	5
	Struktursicht	7
	Source-Code-Hierarchie	9
	Abbildungssicht (Ausführungseinheiten)	10
4	Fazit	11
5	Literaturverzeichnis	12

Abbildungsverzeichnis

3.1	Szenarien	4
3.2	Kontextsicht [2]	5
3.3	Verhaltenssicht: Datenfluss im TensorFlow Graph [3]	6
3.4	Struktursicht: Schichtenarchitektur von TensorFlow [4]	8
3.5	Source-Code-Hierarchie	9
3.6	Abbildungssicht: Single-Machine vs. verteilte Ausführung [1, S. 5]	10

Tabellenverzeichnis

2.1	Anforderungen an TensorFlow	2
2.2	Einflussfaktoren	3
3.1	Kernel Implementierungen	9

1 TensorFlow

TensorFlow ist eine Machine Learning Bibliothek, welche 2015 von Google als Open-Source veröffentlicht wurde. Der Schwerpunkt der Bibliothek liegt auf neuronalen Netzen und tiefen neuronalen Netzen, die in der letzten Zeit eine umfangreiche Anwendung in vielen Bereichen der künstlichen Intelligenz wie Bilderkennung und Sprachanalyse gefunden haben.

TensorFlow wurde als Nachfolger einer anderen Bibliothek für Machine Learning, **DistBelief**, entwickelt. DistBelief wurde im Rahmen des Google Brain Projekts im Jahr 2011 entwickelt, um die Nutzung von hochskalierbaren tiefen neuronalen Netzen (DNN) zu erforschen. Die Bibliothek wurde unter anderem für unsupervised Lernen, Bild- und Spracherkennung und auch bei der Evaluation von Spielzügen im Brettspiel Go eingesetzt. [1, S. 1]

Trotz des erfolgreichen Einsatzes hatte DistBelief einige Einschränkungen:

- die Schichten der Neuronalen Netzwerke (NN) mussten (im Gegensatz zum genutzten Python-Interface) aus Effizienz-Gründen mit C++ definiert werden.
- die Gradientenfunktion zur Optimierung der Gewichte erforderte eine Anpassung der Implementierung des integrierten Parameter-Servers.
- nur vorwärtsgerichtete Algorithmen möglich, jedoch nicht rekurrente NN oder Reinforcement Learning.
- wurde nur für die Anwendung auf großen Clustern von Multi-Core-CPU-Servern entwickelt, keine Unterstützung von GPUs oder anderen Prozessoren. [2]

Aus den Erfahrungen mit DistBelief wurde gelernt und diese Erfahrungen wurden bei der Entwicklung von TensorFlow berücksichtigt. Interessant ist, dass DistBelief zwar als Prototyp für TensorFlow genommen wurde, an dem verschiedene Funktionalitäten ausprobiert und getestet wurden, allerdings wurde TensorFlow komplett neu entwickelt. Das ist ein Beispiel dafür, dass Prototypen sehr praktisch sind, dass es jedoch auch wichtig ist, deren Vor- und Nachteile zu bewerten und im Laufe der Entwicklung Prototypen auch zu verwerfen. [1, S. 2]

Im Weiteren werden die Anforderungen verschiedener Benutzergruppen beschrieben und die Architektur der Bibliothek ausführlich erläutert.

2 Anforderungsanalyse

TensorFlow wird von verschiedenen **Benutzergruppen** verwendet:

- Forscher, Studenten, Wissenschaftler
- Architekten und Software Engineer
- Software Entwickler
- Hardware Hersteller.

Die Bibliothek wird vor allem zur Entwicklung der Anwendungen mit AI-Funktionalitäten eingesetzt. Zusätzlich wird sie zur Forschungszwecken im Bereich Machine Learning zur Entwicklung der neuen Algorithmen und Modelle verwendet. Außerdem gehören auch Hardware-Hersteller zu einer der Benutzergruppen von TensorFlow, die ihre Produkte (zB. CPUs, GPUs etc.) für Machine Learning-Zwecke optimieren wollen.

Anforderungen

Aus diesen Anwendungsfällen lassen sich die **Anforderungen** an die Bibliothek ableiten, die nach FURPS-Merkmalen aufgeteilt werden können. FURPS steht für:

- Functionality (Funktionalität)
- Usability (Benutzbarkeit)
- Reliability (Zuverlässigkeit)
- Performance (Effizienz)
- Supportability (Änderbarkeit, Wartbarkeit)

Tabelle 2.1: Anforderungen an TensorFlow

ID	Kurzbeschreibung	Anforderung
F1	ML und DL Funktionalitäten	Da Machine Learning auf mathematischen Berechnungen beruht, muss TensorFlow Vektor- bzw Matrizen-Operationen und andere Rechenoperationen aus Linearen Algebra und Statistik bereitstellen. Viele Trainingsalgorithmen benötigen Gradienten, deshalb muss TensorFlow diese selbst bestimmen können.

ID	Kurzbeschreibung	Anforderung
U1	Protoyping	TensorFlow muss eine Möglichkeit zum schnellen Definieren und Testen von Modellen bereitstellen.
U2	Produktiver Einsatz	TensorFlow muss für den produktiven Einsatz (vor allem Inference) geeignet sein.
P1	Performance	Da Maschine Learning durch Rechenleistung limitiert ist, muss TensorFlow die verfügbaren Ressourcen effizient nutzen.
P2	Skalierbarkeit	TensorFlow muss mit sehr großen Datenmengen umgehen können.
S1	Portabilität	Die Bibliothek muss auf verschiedene Systeme portierbar sein und unterschiedliche Acceleratoren (GPU, TPU) unterstützen.
R1	Recovery	Der Trainingsfortschritt soll nach einem Absturz wiederherstellbar sein

Einflussfaktoren

Folgende organisatorische, technische und produktbezogene Faktoren können einen Einfluss auf die Architektur-Entscheidung beeinflusst haben.

Tabelle 2.2: Einflussfaktoren

Faktor-Index	Beschreibung
O1	Community, welche verwendet und Contributions macht
O2	Entwickler und interne Nutzer haben Kenntnisse in C++ und Python
T1	Es werden neue Acceleratoren entwickelt
T2	Die Rechenleistung einer Maschine ist begrenzt, weshalb horizontal skaliert werden muss
T3	Auf Clustern und im Produktiven Einsatz kommt vor allem Linux zum Einsatz, die User verwenden oft OS X oder Windows. Es muss aber auch auf noch unbekannten Betriebssystem einsetzbar sein.
P1	Neue Bibliotheken können integriert werden
P2	Modell kann sehr komplex werden und viele Daten involvieren

3 Architekturentwurf

Im Weiteren werden 4+1 Sichten der TensorFlow-Architektur dargestellt: Szenarien, Kontext-Sicht, Verhaltenssicht, Struktursicht, Abbildungssicht.

Szenarien

Die Hauptbenutzer von TensorFlow sind 1) Software-Architekten und Engineure, die ML-Anwendungen entwerfen und schnelle Prototypen benötigen 2) Entwickler, die ML-Anwendungen für den produktiven Einsatz entwickeln 3) Studierenden und Wissenschaftler, die das Framework für das Experimentieren und die Entwicklung neuer ML-Algorithmen verwenden.

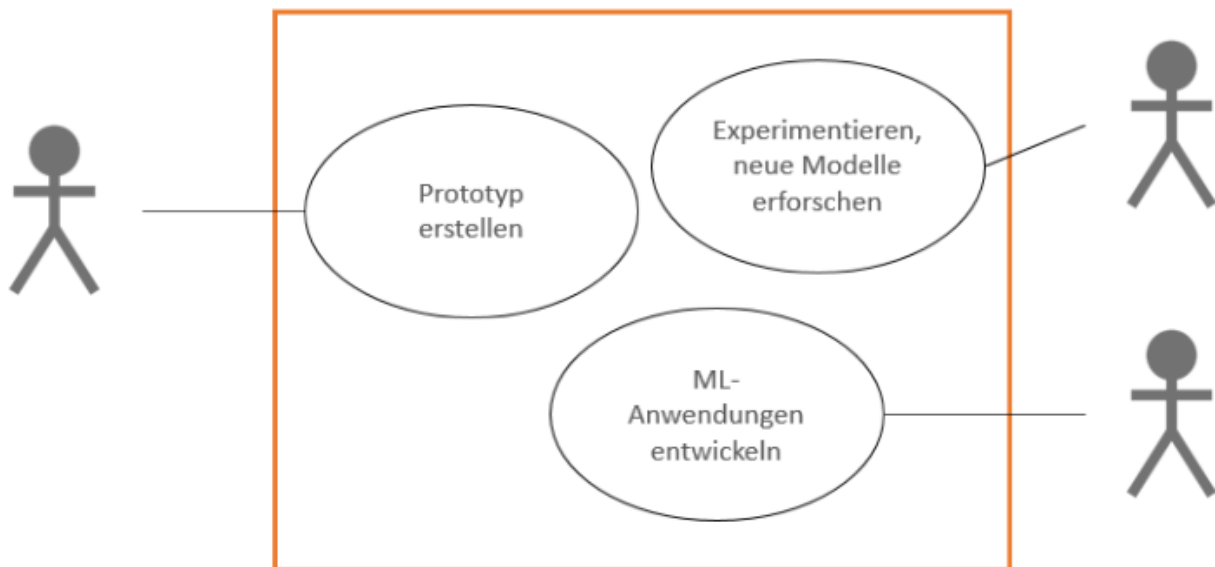


Abbildung 3.1: Szenarien

Kontext-Sicht

TensorFlow wurde ursprünglich von Google entwickelt und ist auch immer noch unter der Kontrolle von Google. Auch wenn das Projekt Open Source ist, trägt Google im Wesentlichen der Weiterentwicklung von TensorFlow bei, steuert den Prozess und unterstützt die Contributors und die Community. Zudem

sind Firmen, die das Framework einsetzen ebenfalls an der Weiterentwicklung des Projekts interessiert, ebenso wie die Integrators, die vor allem an der schnellen Performance und Unterstützung für ihre Plattformen interessiert sind. Die Wissenschaftler legen einen großen Wert auf die Einfachheit der Verwendung, die Möglichkeit der schnellen Entwicklung der Prototypen, sowie Hilfstools (Visualisierungen wie Tensorboard, Debugging etc.)

Zur Versionsverwaltung und Collaboration kommt ein öffentliches GitHub Repository zum Einsatz. Neue Versionen werden automatisch von einer Jenkins CI für verschiedene Plattformen gebaut und getestet.

TensorFlow verwendet externe Bibliotheken, beispielsweise für Lineare Algebra oder die CUDA Schnittstelle für Nvidia GPUs. Viele der High Level Bibliotheken sind in Python und das Backend in C++ geschrieben, weshalb es einen Python Interpreter und eine C++ Laufzeit zum Ausführen benötigt und einen C++ Compiler zum Kompilieren.

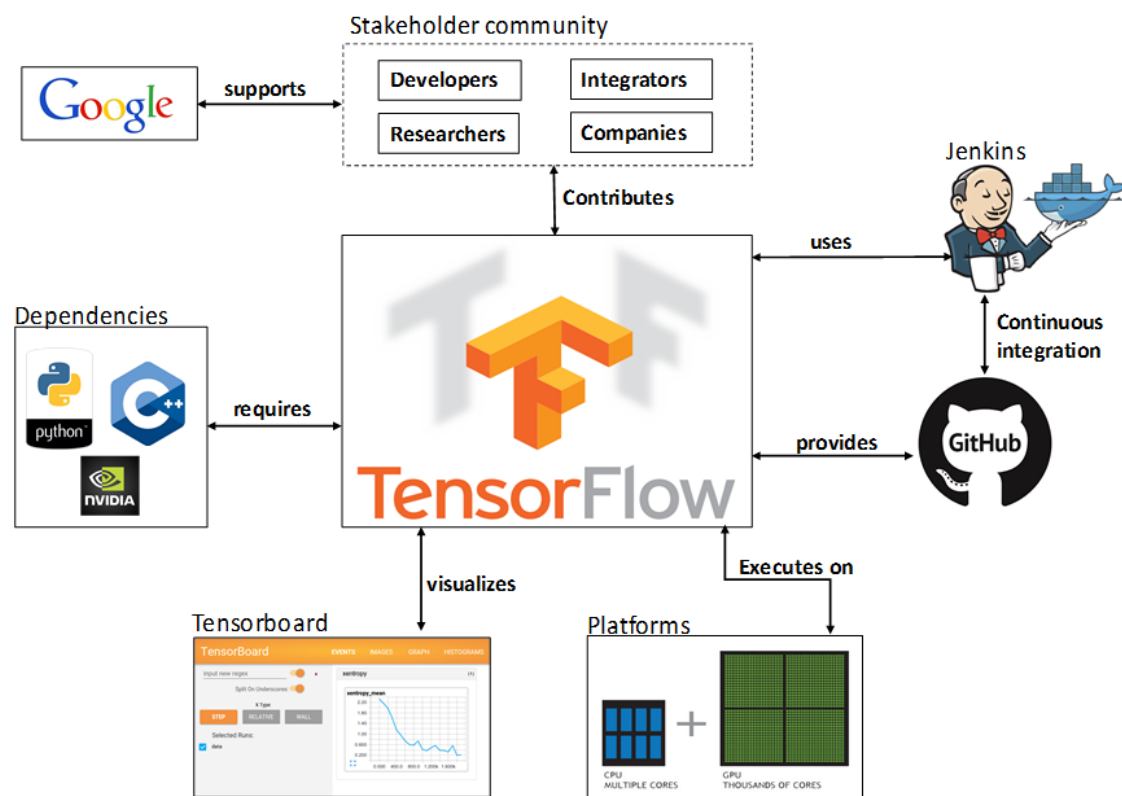


Abbildung 3.2: Kontextsicht [2]

Verhaltenssicht (Architekturbausteine)

In TensorFlow werden Berechnungen als Graphen dargestellt. Diese Graphen lassen sich innerhalb einer Session ausführen. In den Graphen gibt es drei Grundarten von Knoten: Operationen, Placeholder und Variablen. Placeholder werden beim Ausführen durch einen konkreten Wert ersetzt. Sie stellen

Eingabewerte (hier der Input Node) dar. Variablen halten Werte, die in der Session gespeichert und verändert werden können. Hier sind das beispielsweise die Weights W und Biases b . Operationen sind hier beispielsweise Matrix Multiplikation *MatMul* oder *BiasAdd*. Die Ein- und Ausgabewerte der Knoten sind jeweils Tensoren, welche entlang der Kanten „fließen“. Ein Subgraph lässt sich zu einer Komponente zusammenfassen, hier sind das *ReLuLayer*, *LogitLayer* und *SDGTrainer*.

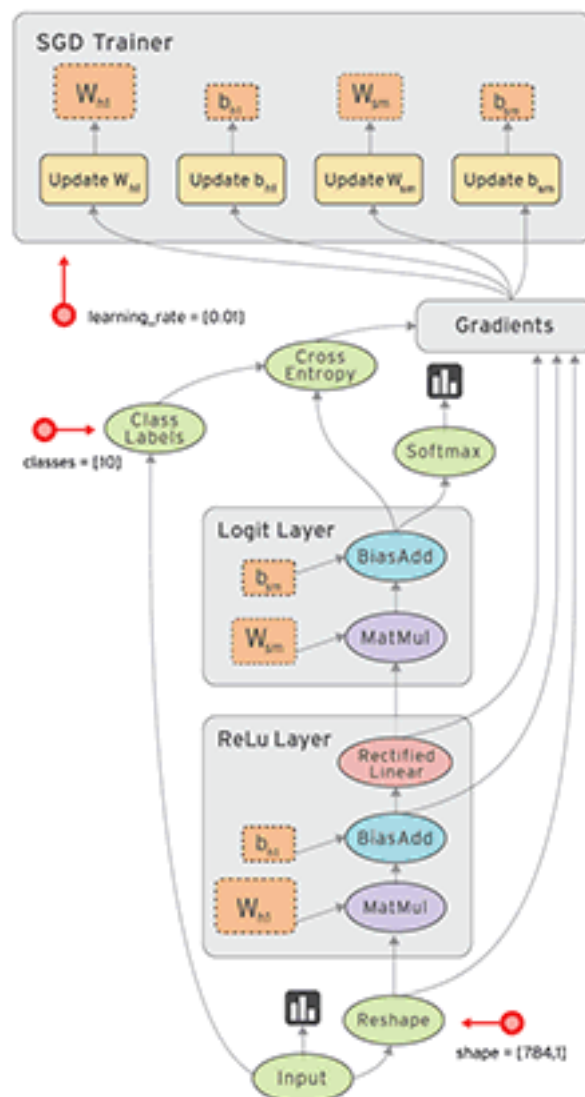


Abbildung 3.3: Verhaltenssicht: Datenfluss im TensorFlow Graph [3]

Der Graph stellt ein Neuronales Netzwerk mit zwei Layern dar, welches Classification macht und über Statistic Gradient Descent trainiert wird. Die Trainingsdaten werden im *Input* Placeholder eingegeben und in Labels und die Feature Matrix aufgeteilt. Die Feature Matrix hält die Eingabedaten für den Forwardpasses durch das Neuronale Netz genutzt. In vektorisierter Form lässt sich die Multiplikation

jedes Features mit dem entsprechenden Gewicht für alle Samples als Matrixmultiplikation ausdrücken. Der erste Layer nutzt ReLu als *activation function*, deren Ausgabe Matrix die Eingabe für den zweiten Layer ist.

Für das Training werden die Labels als One-Hot-Vektor kodiert (*ClassLabels*) und über die *CrossEntropy* Cost-Function mit der Ausgabe des letzten Layers Netzes verglichen. Aus Performancegründen ist die Softmax Funktion im *CrossEntropy* Node enthalten. Der Trainingsprozess minimiert die Cost-Fuction für die Trainingsdaten, indem mit Hilfe von Gradient Descent die Variablen W und b in kleinen Schritten angepasst werden. Anhand der partiellen Ableitungen (Gradients) nach den Variablen ergibt sich die Richtung in der sich das Minimum für das jeweilige Sampe befindet und entsprechend werden die Variablen geupdated in den *Update* angepasst. Das geschieht in mehreren Iterationen.

Bei Inference wird die Ausgabe des letzten Layers durch die Softmax-Funktion in den Interval $[0,1]$ gebracht, was der Wahrscheinlichkeit entspricht, mit der das Netz ein Sample einer Klasse zuordnet. Das Netz nutzt dazu die in der Session gespeicherten trainierten *Weights* und *Biases*. Der Gleiche Graph kann auch in unterschiedlichen Session für unterschiedliche Daten trainiert werden.

Struktursicht

Tensorflow ist in mehreren Schichten organisiert. Diese reichen von einer Geräte-spezifischen Schicht (unten) bis zu High Level Training und Inference Bibliotheken (oben). Der Tensorflow Core stellt seine Funktionalität über eine Low-Level C API bereit. Diese Low-Level API wird durch High-Level APIs für verschiedene Client-Sprachen, wie Python, C++, Java und Go gekpaselt. Unter Verwendung der Sprachspezifischen APIs gibt es High-Level Bibliotheken für Training und Inference.

Diese Schichtenarchitektur erlaubt ein hohes Maß and Flexibilität und Portabilität. So kann auf dem Device Layer beispielsweise Unterstützung für Acceleratoren wie GPUs und TPUs hinzugefügt werden, Kernelimplementationen hinzugefügt oder ersetzt werden und eine zusätzliche Schnittstelle für eine andere Sprache hinzugefügt werden.

High-Level Python Bibliotheken erlauben das schnelle Prototyping und Training von Modellen und Algorithmen. Die C++ und Java Clients dagegen untersützt das Einbinden trainierter Modelle in Produk-tivsysteme, auf welchen hohe Inference Performance gefordert ist.

Der Distribution Master ist dafür verantwortlich die Berechnungen auf mehrere Dataflow Executer auf-zuteilen. Dabei werden transparent *Send* und *Recive* Nodes an den Kanten eingefügt, an denen der Graph partitioniert wird. Die Dataflow Executer können dabei auf mehrere Maschienen verteilt werden, die passende Kommunikation wird vom Network Layer abstrahiert.

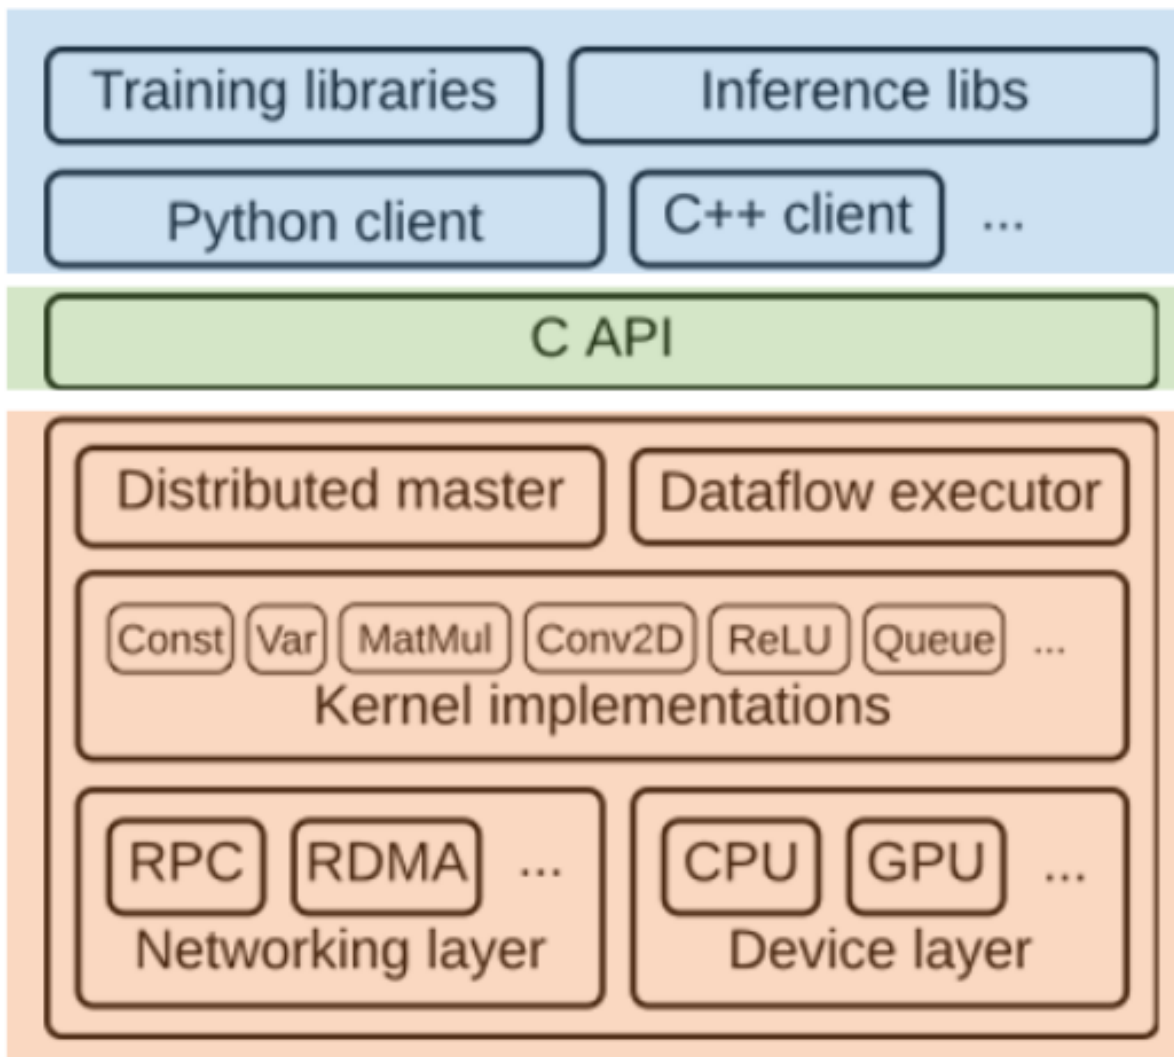


Abbildung 3.4: Struktursicht: Schichtenarchitektur von TensorFlow [4]

Kernels

- Kernels sind C++ Implementierungen von Operationen, die speziell für die Ausführung auf einer bestimmten Recheneinheit wie CPU oder GPU entwickelt wurden. Da sie zu nativem Maschinencode kompiliert werden und sehr hardwarenah geschrieben sind, können sie diese optimal ausnutzen und sehr hohe Performance erzielen.
- Die TensorFlow enthält mehrere solche eingebaute Operationen/Kernels. Beispiele dafür sind:

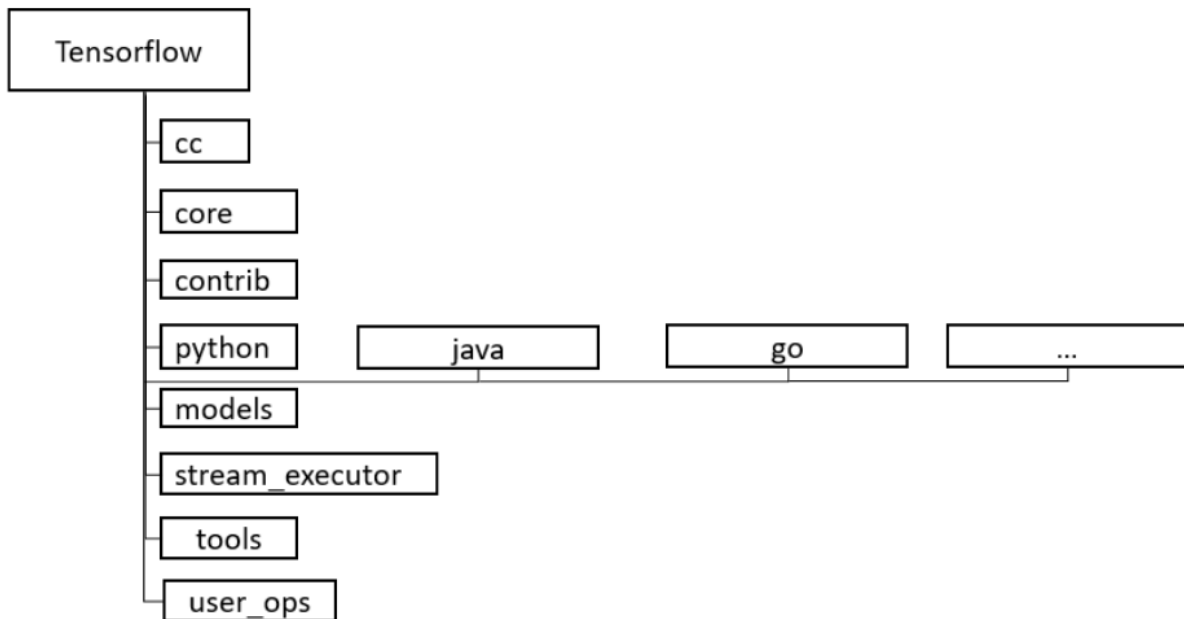
Tabelle 3.1: Kernel Implementierungen

Kategorie	Beispiele
Elementweise mathematische Operationen	Add, Sub, Mul, Div, Exp, Log, Greater, Less, Equal
Array-Operationen	Concat, Slice, Split, Constant, Rank, Shape, Shuffle
Matrix-Operationen	MatMul, MatrixInverse, MatrixDeterminant
Variablen und Zuweisungsoperationen	Variable, Assign, AssignAdd
Elemente von Neuronale Netzen	SoftMax, Sigmoid, ReLU, Convolution2D, MaxPool
Checkpoint-Operations	Save, Restore
Queue und Synchronisationsoperationen	Enqueue, Dequeue, MutexAcquire, MutexRelease
Flusskontroll-Operationen	Merge, Switch, Enter, Leave, NextIteration

Außerdem unterstützt TensorFlow das Einbinden eigener Kernel.

Source-Code-Hierarchie

Die Architektur lässt sich in den Verzeichnissen auf TensorFlow-GitHub wiedererkennen. Die Code-Hierarchie enthält folgende Verzeichnisse [5]:

**Abbildung 3.5:** Source-Code-Hierarchie

- cc: Funktions-Wrapper für den C++ Code.
- core: Implementierung der Hauptfunktionalitäten von TensorFlow.
- contrib: Neue Features, die von den Contributors zum Open Source Projekt beigetragen werden und später unter Umständen in den Core übertragen werden können.
- models: Modelle für spezielle ML Anwendungsfälle.
- python: Python API.
- java: Java API.
- go: Go API.
- stream-executor: Interface für Hardware-Acceleratoren (z.B. GPUs).
- tools: Entwicklungsumgebung für das Framework.
- user_ops: Wrapper für die Benutzer-spezifischen (angepassten) Funktionen. [2]

Abbildungssicht (Ausführungseinheiten)

Die in TensorFlow erstellten Programme (Modelle) können sowohl lokal auf einem System, als auch verteilt auf mehreren Systemen ausgeführt werden. Der Master-Prozess kümmert sich um die Verteilung der Operationen zwischen den verfügbaren Ressourcen.

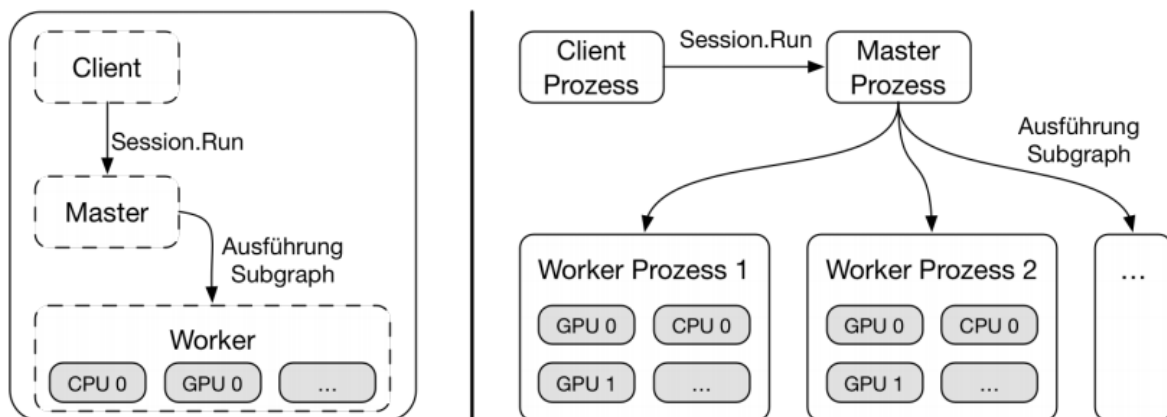


Abbildung 3.6: Abbildungssicht: Single-Machine vs. verteilte Ausführung [1, S. 5]

4 Fazit

Zusammenfassend lässt sich festhalten, dass sich die Anforderungen an das ML-Framework in der Architektur von TensorFlow wieder finden. Das Framework bietet die wesentlichen **Machine Learning Funktionalitäten** mit einer Spezialisierung für Deeplearning (breite Gradient Descent Unterstützung). Die High-Level API erleichtert die Erstellung von Prototypen, während die Low-Level API die Möglichkeit bietet, flexibel zu bleiben und die Modelle anzupassen, um allen Anforderungen für produktiven Einsatz gerecht zu werden.

Der Device Layer sorgt für die notwendige Abstraktion von der Hardware für die **Portabilität**, damit Tensorflow mit verschiedenen Acceleratoren verwendet werden kann. Die datenfluss-basierte Funktionsweise sowie die Komponenten Distributed Master, Dataflow Executor und Worker Services bieten die Möglichkeiten, Graphen verteilt auszuführen. Dadurch ist auch die **Skalierbarkeit** gewährleistet. Die Persistierung von Checkpoints sorgt für eine schnelle **Recovery**, was besonders für längeres Training relevant ist. Die hardwarenahe Implementation der Funktionalitäten in C++ und die Kernel-Implementierungen sorgen zudem für eine schnelle **Performance**.

5 Literaturverzeichnis

1. DEAN, Jeffrey, CORRADO, Greg, MONGA, Rajat, CHEN, Kai, DEVIN, Matthieu, MAO, Mark, SENIOR, Andrew, TUCKER, Paul, YANG, Ke und LE, Quoc V. Large scale distributed deep networks. *Advances in Neural Information Processing Systems* [online]. 2012. P. 1223–1231. DOI 10.1109/ICDAR.2011.95. Available from: <http://download.tensorflow.org/paper/whitepaper2015.pdf>
2. CHAN-ZHENG, Carmen, VERDIESEN, Ilse, CARVAJAL-GODINEZ, Johan und SAILESH MANI, Pranav. *TensorFlow™ - Open Source Library for Machine Learning Applications* [online]. 2017. Available from: <https://delftswa.gitbooks.io/desosa2016/content/tensorflow/chapter.html>
3. TENSORFLOW. *TensorFlow: Graphs and Sessions* [online]. 2018. Available from: https://www.tensorflow.org/programmers_guide/graphs
4. TENSORFLOW. *TensorFlow Architecture* [online]. 2018. Available from: <https://www.tensorflow.org/extend/architecture>
5. TENSORFLOW. *TensorFlow GitHub* [online]. 2018. Available from: <https://github.com/tensorflow/tensorflow/tree/master/tensorflow>